Relatório Executivo: Análise Exploratória e Engenharia de Dados

1. O que foi feito na Análise Exploratória (EDA) e Resultados

- **Não-normalidade comprovada:** O teste de Shapiro-Wilk rejeitou a hipótese de normalidade para todas as variáveis-alvo (CTR, CPM, custo, impressões, cliques) nos três estágios do funil, com p-valores entre 10^{-27} e 10^{-43} — invalidando qualquer método paramétrico.
- **CPM multimodal e estratificado:** A distribuição agregada do CPM apresenta múltiplos picos que se dissolvem em distribuições unimodais ao estratificar por estágio do funil, confirmando que *Awareness*, *Consideration* e *Conversion* operam em contextos de leilão estruturalmente distintos.
- **Correção Pearson → Spearman:** Auditoria sistemática do repositório identificou 17 artefatos usando Correlação de Pearson sobre dados com assimetria extrema à direita; todos foram corrigidos para Spearman, que avalia relações monotônicas independentemente da magnitude dos outliers.

EDA Etapa 1 — Distribuições das Variáveis-Alvo

Gráfico 1: Distribuições de CTR, CPM, Custo, Impressões e Cliques

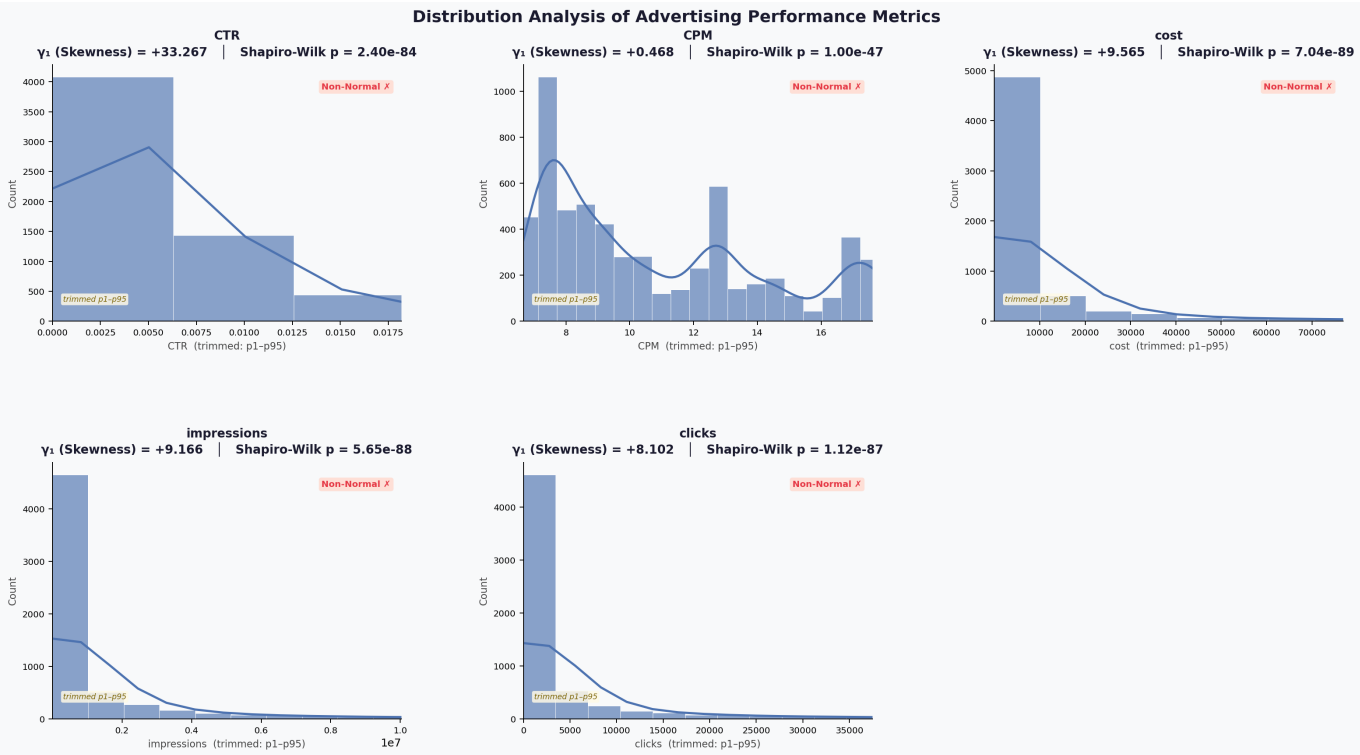

Tabela 1: Teste de Normalidade Shapiro-Wilk — Todas as Variáveis-Alvo

Variável	N (válido)	Assimetria (γ_1)	Shapiro-Wilk p	Normalidade
CTR	6.244	+33,2673	2,40e-84	❌ REJEITADA
CPM	6.244	+0,4684	1,00e-47	❌ REJEITADA
cost	6.244	+9,5654	7,04e-89	❌ REJEITADA

Variável	N (válido)	Assimetria (γ_1)	Shapiro-Wilk p	Normalidade
impressions	6.244	+9,1658	5,65e-88	❌ REJEITADA
clicks	6.244	+8,1022	1,12e-87	❌ REJEITADA

Interpretação: A hipótese nula foi rejeitada para todas as 5 variáveis. Os dados possuem assimetria extrema à direita, exigindo métodos não-paramétricos (Spearman).

EDA Etapa 2 — CPM Estratificado por Estágio do Funil

Gráfico 2: Distribuição de CPM por Etapa do Funil

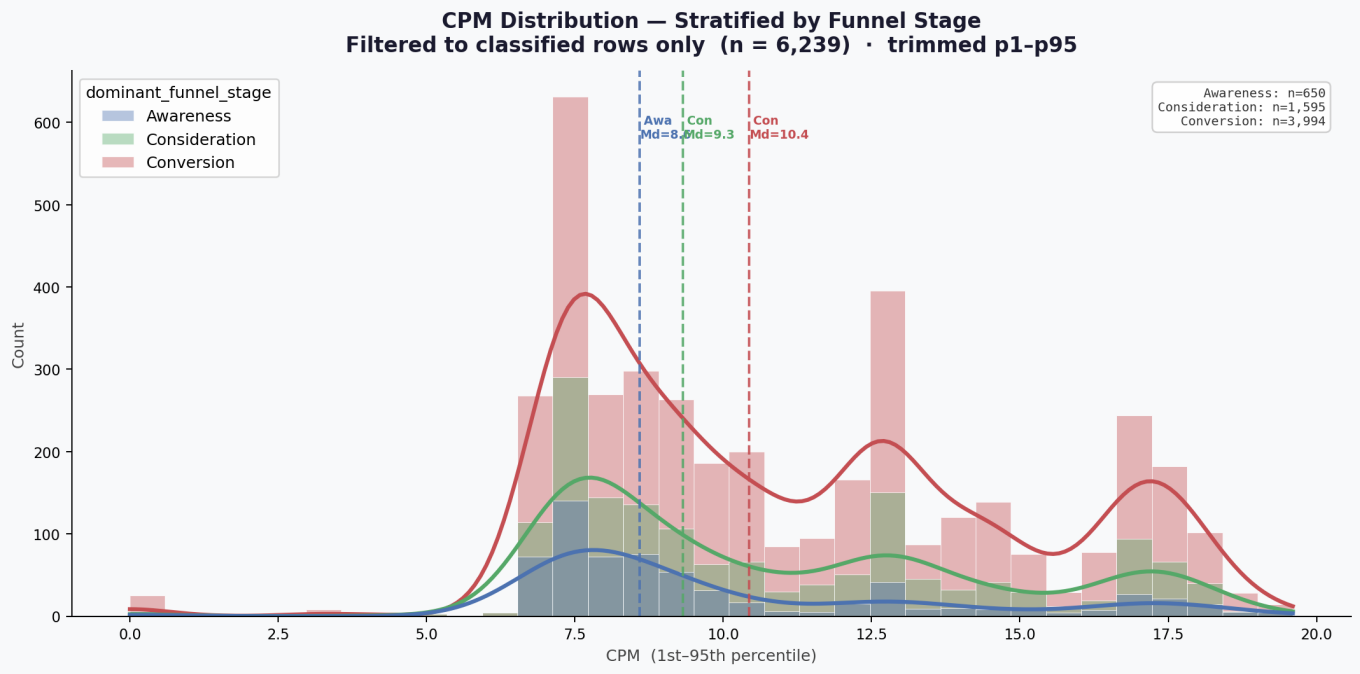

Interpretação: O estágio de Conversão concentra as densidades de CPM mais elevadas, confirmando que leilões direcionados à base do funil operam com preços de *clearing* estruturalmente superiores.

EDA Etapa 3A — Eficiência CPM vs CTR por Estágio

Gráfico 3: Dispersão CPM vs CTR com Regressão OLS por Estágio

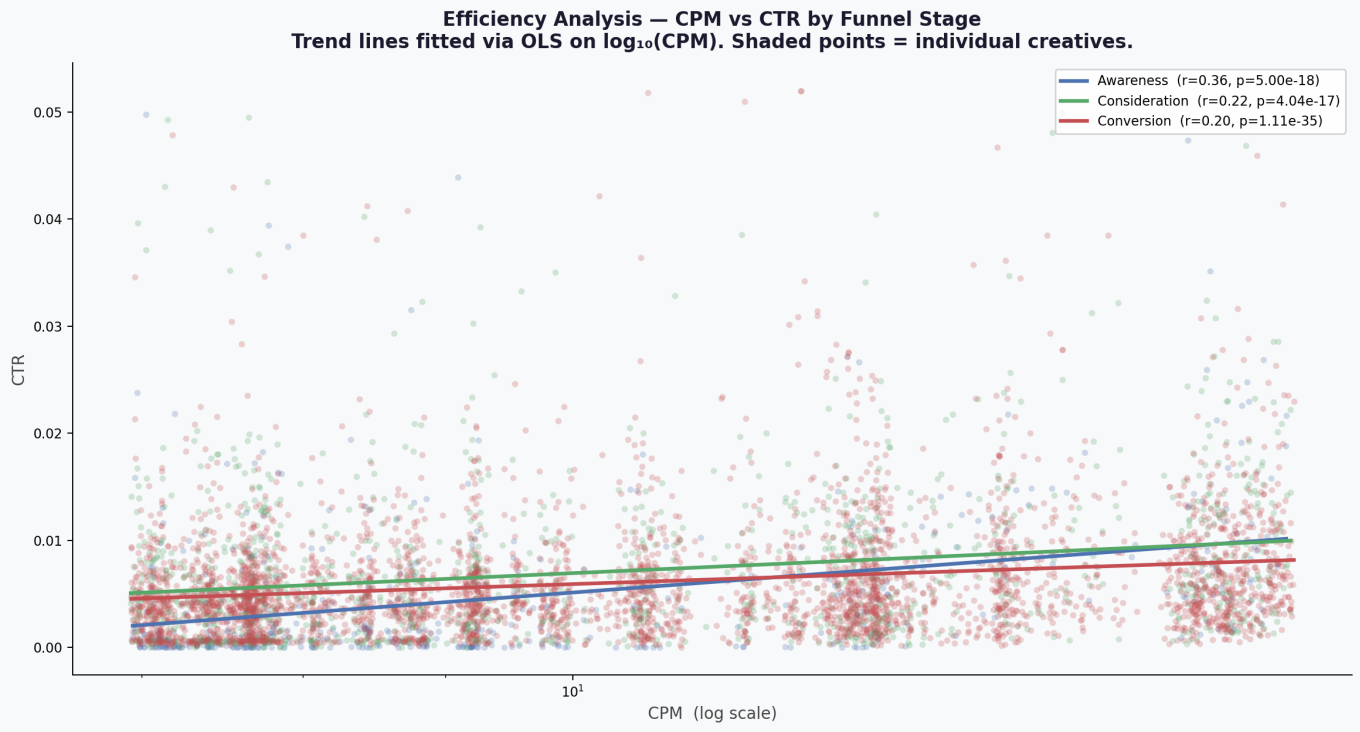

Tabela 3: Sumário de Eficiência por Estágio do Funil

Estágio	CPM Médio	CPM Mediana	CTR Médio	CTR Mediana	Razão CPM/CTR
Awareness	9,97	8,60	0,00499	0,00129	1.996,2
Consideration	10,79	9,33	0,00888	0,00486	**1.214,6** 🥇
Conversion	11,14	10,44	0,00645	0,00450	1.727,2

Interpretação: Embora a Conversão seja 11,7% mais cara em CPM, o ganho de +29,1% em CTR justifica o prêmio — e o estágio de *Consideration* supera ambos em eficiência de custo-por-clique (razão CPM/CTR = 1.214,6).

EDA Etapa 3B — ANOVA e Teste Tukey HSD

Gráfico 4: Boxplot $\log_{10}$(CPM) e Matriz de p-valores Tukey HSD

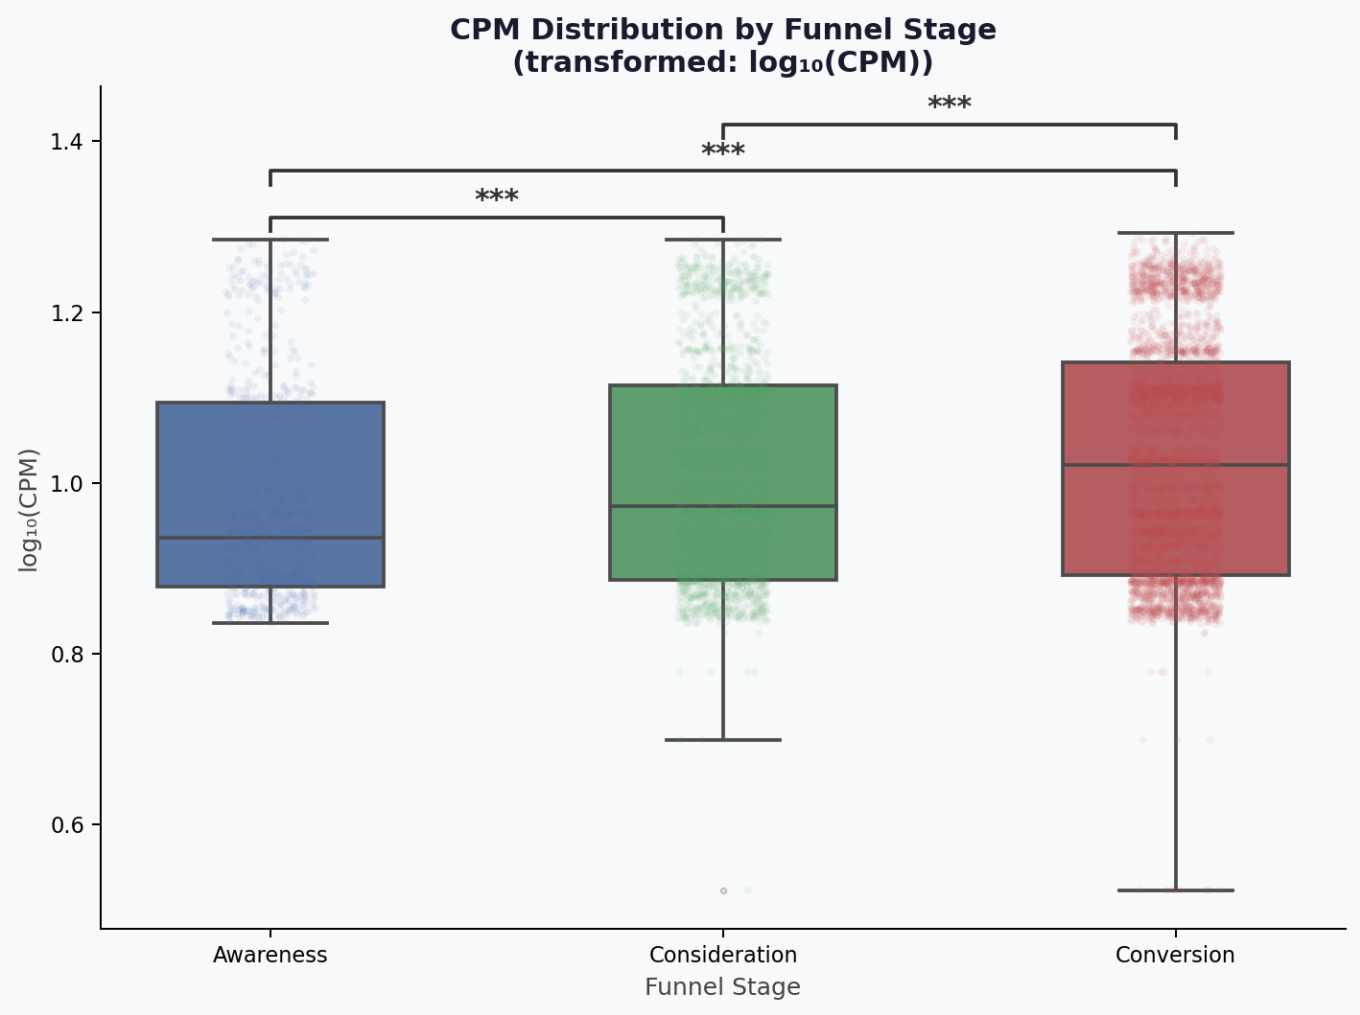

Tabela 4: Teste de Normalidade por Grupo (Shapiro-Wilk sobre CPM)

Estágio	Estatística W	p-valor	Normal?
Awareness	0,7991	1,75e-27	❌ Não
Consideration	0,8848	8,52e-33	❌ Não
Conversion	0,9096	1,45e-43	❌ Não

Tabela 5: One-Way ANOVA sobre $\log_{10}$(CPM)

Estatística F	p-valor	α	Decisão sobre H_0
34,56	**1,19e-15**	0,05	**REJEITADA ✕**

Tabela 6: Tukey HSD — Comparações Par a Par

Par Comparado	Estatística	p-valor	Significância
Awareness vs. Consideration	−0,0317	1,87e-06	***
Awareness vs. Conversion	−0,0465	6,94e-13	***
Consideration vs. Conversion	−0,0148	7,43e-04	***

Interpretação: A ANOVA ($F = 34{,}56$; $p = 1{,}19 \times 10^{-15}$) e o Tukey HSD provam matematicamente que a diferença de custo entre os três estágios é estatisticamente significante em todos os pares ($p < 0{,}001$).

---

2. Reestruturação dos Embeddings Neurais (Imagens e Vídeos)

Os dados brutos de *embeddings* fornecidos pela supervisão do projeto apresentavam dimensionalidades incompatíveis: vídeos eram representados como matrizes **T×10** (onde T é o número de frames ao longo do tempo) e imagens como vetores fixos **1×10**. Para unificá-los em formato tabular de largura fixa, aplicamos a seguinte transformação:

- **Vídeos (T×10 → 1×20):** Extraímos a **média** (μ) e a **variância** (σ^2) ao longo do eixo temporal para cada uma das 10 dimensões latentes, achatando a matriz em um vetor de 20 valores — 10 médias + 10 variâncias.
- **Imagens (1×10 → 1×20):** Mantivemos os 10 valores originais como a componente de "média" e preenchemos as 10 posições de variância com **zeros**, pois imagens são estáticas e não possuem dinâmica temporal mensurável.

Tabela 7: Estrutura do Vetor 1×20 no `df_master`

Posição	Colunas	Momento	Interpretação
Dim. 1–10	`img_emb_0` … `img_emb_9`	Média (μ)	Assinatura visual estática do criativo
Dim. 11–20	`vid_emb_0` … `vid_emb_9`	Média (μ)	Engajamento neural médio ao longo do vídeo

Essa reestruturação garantiu que todos os 6.244 criativos do `df_master` passassem a ter a mesma dimensão **1×20**, viabilizando a incorporação direta dessas variáveis como preditores numéricos na construção futura do modelo preditivo.