Análise Exploratória e Modelagem Preditiva de Performance Cognitiva de Anúncios

1. Engenharia de Dados e Triagem

Lógica de Preenchimento com Zeros (Zero-Padding)

O dataset original contém tanto anúncios em vídeo quanto imagens estáticas. Os nossos embeddings neurais, agora, geram 20 dimensões cognitivas por frame de vídeo, resultando em estatísticas de **média** (`cognitive_mean_0` … `cognitive_mean_9`) e **variância** (`cognitive_var_0` … `cognitive_var_9`) ao longo da série temporal.

Para **imagens estáticas**, existe apenas um único frame — logo, a variância temporal é zero por definição. Esses registros recebem preenchimento com zeros (`0.0`) em todas as colunas de variância, preservando a integridade dimensional do dataset sem introduzir informação espúria. A flag booleana `is_video` (derivada de `(cognitive_var > 0).any()`) permite isolar o subconjunto de vídeos sempre que necessário.

Intervenção Crítica de Qualidade de Dados

Durante a análise exploratória, identificamos um registro com valor de `cognitivedemand` igual a **7.100.000** (7,1 milhões) — uma anomalia que excede em seis ordens de magnitude a distribuição esperada da variável (mediana ≈ 60–80). Este artefato corrompido, provavelmente originado de um erro de pipeline do fornecedor, foi **removido por hard-drop** (threshold: `cognitivedemand > 1000`) antes da etapa de clusterização final.

A remoção dessa única linha eliminou o terceiro cluster espúrio que aparecia na tentativa inicial com K=3 (o cluster inteiro consistia apenas desse outlier), permitindo uma segmentação limpa com K=2.

---

3. Auditoria de Features e Redução de Dimensionalidade

Diagnóstico de Multicolinearidade

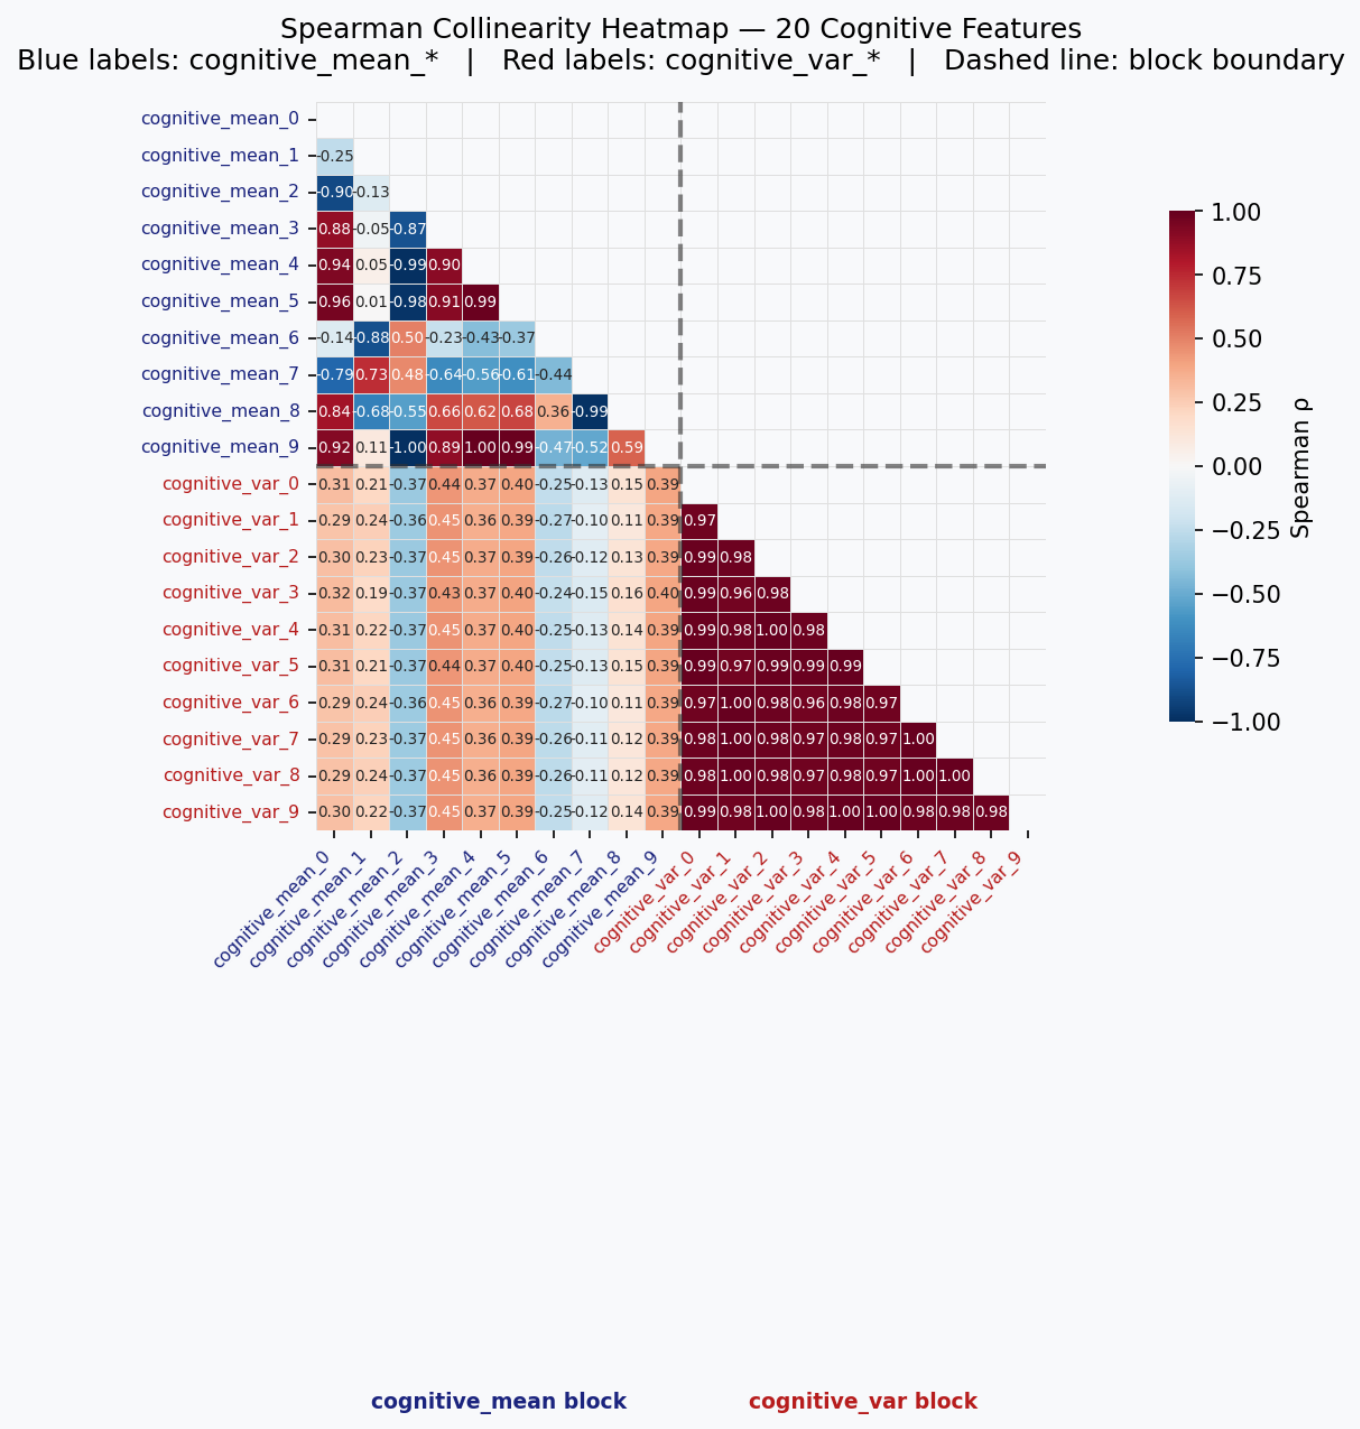

Figura 3.1 — Matriz de correlação entre as 20 dimensões cognitivas brutas do fornecedor.

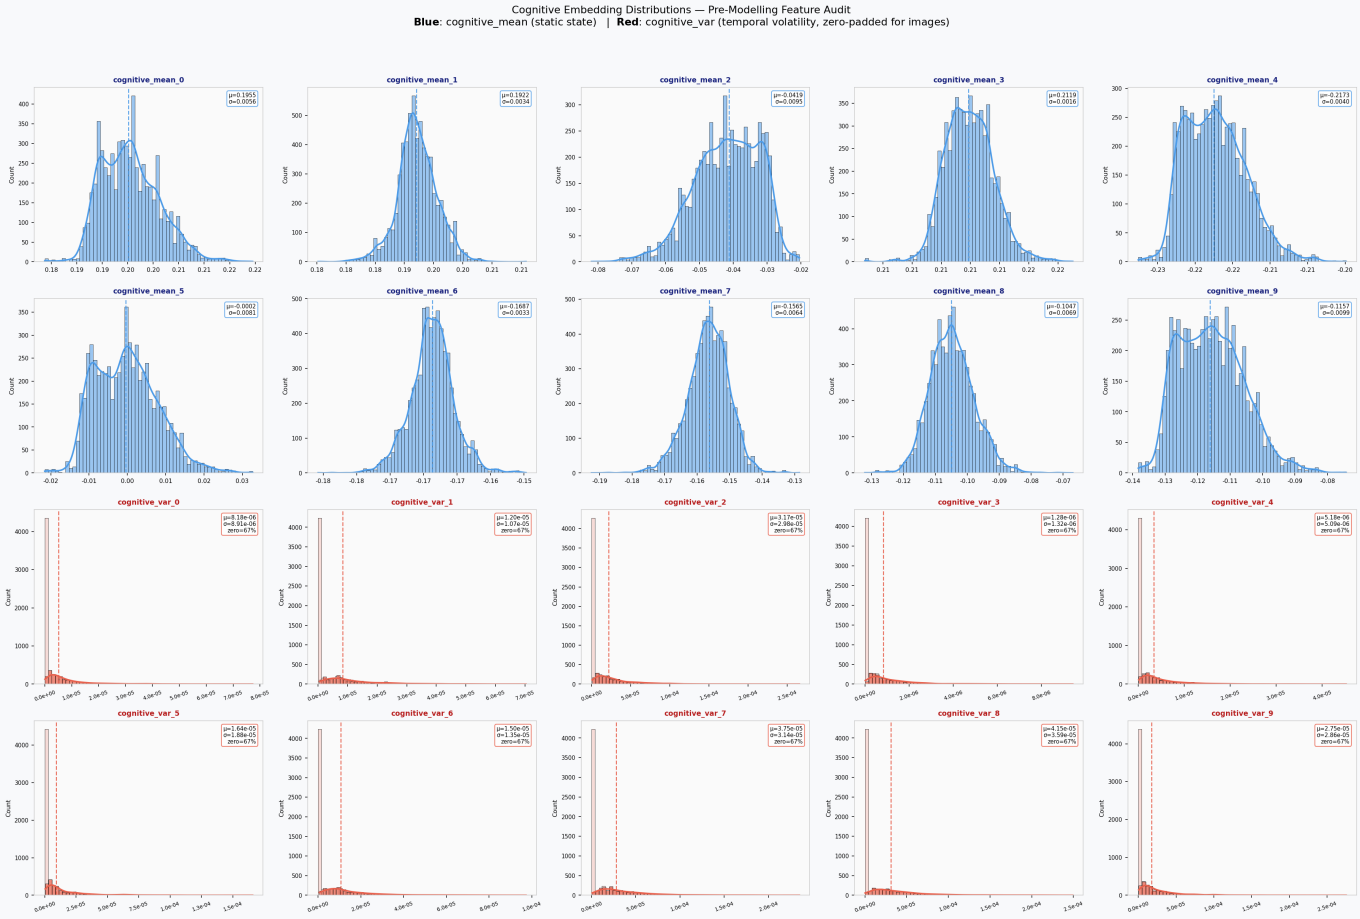

Figura 3.2 — Distribuições das dimensões cognitivas brutas.

Narrativa

As 20 dimensões cognitivas fornecidas pelo parceiro de neurociência apresentavam **multicolinearidade severa**, com coeficientes de correlação de Pearson atingindo ρ ≈ 0,97 entre pares de features. Modelos de regressão e classificação treinados diretamente sobre essas variáveis sofreriam de instabilidade numérica, inflação de variância dos coeficientes e perda de interpretabilidade.

Para resolver esse problema, executamos **Análise de Componentes Principais (PCA)** separadamente sobre os dois blocos de features:

Bloco	Features originais	Componentes retidas	Variância explicada
Média (mean)	10	2	> 90%
Variância (var)	10	2	> 90%

O resultado foi a compressão das 20 dimensões ruidosas em **4 sinais ortogonais** — `pca_mean_1`, `pca_mean_2`, `pca_var_1` e `pca_var_2` — que capturam mais de 90% da variância total, eliminando a redundância e produzindo features interpretáveis e estatisticamente independentes para os modelos subsequentes.

---

4. O Pivô da Modelagem Preditiva — A Morte da Correlação Linear

Correlação entre Features Neurais e Métricas Financeiras

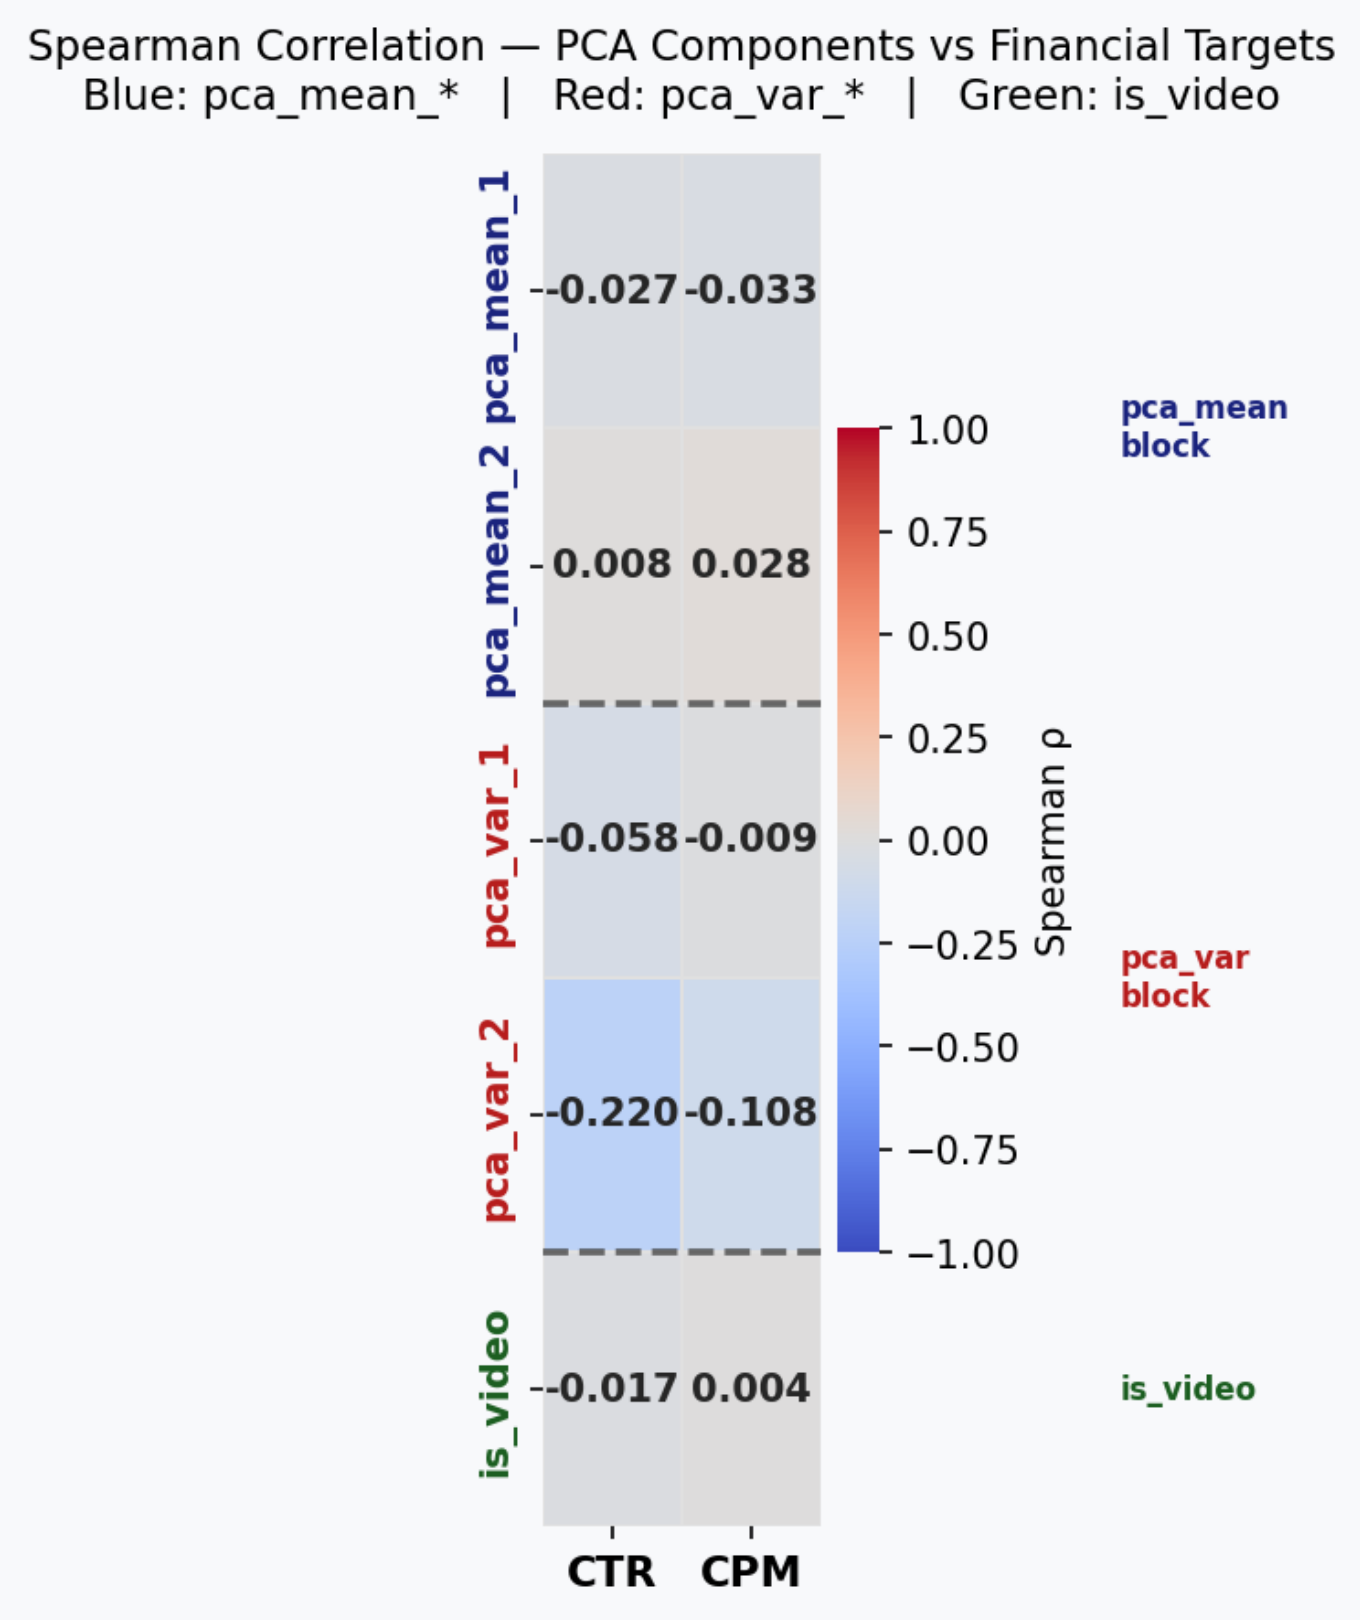

Figura 4.1 — Mapa de correlação entre componentes PCA, métricas neurais e variáveis financeiras (CTR, CPM).

---

5. A Solução de Negócios: Classificação e Análise SHAP

Mudança de Estratégia

Diante da impossibilidade de prever o CTR de forma contínua, adotamos uma abordagem de **classificação binária**: agrupar anúncios por Etapa do Funil (Awareness, Consideration, Conversion) e classificá-los como **"Top Performers"** (acima do Percentil 75 de CTR dentro de seu respectivo grupo).

Este modelo (**XGBClassifier** — XGBoost, um algoritmo de gradient boosting que treina sequências de árvores de decisão, onde cada árvore corrige os erros da anterior, resultando em alta acurácia com controle de overfitting) alcançou um score **ROC-AUC de ~0,80** — demonstrando que, embora os sinais neurais não prevejam o valor exato do CTR, são capazes de distinguir com alta acurácia os criativos de alta performance daqueles de baixa performance dentro de cada contexto de funil.

Análise SHAP — Interpretabilidade Global

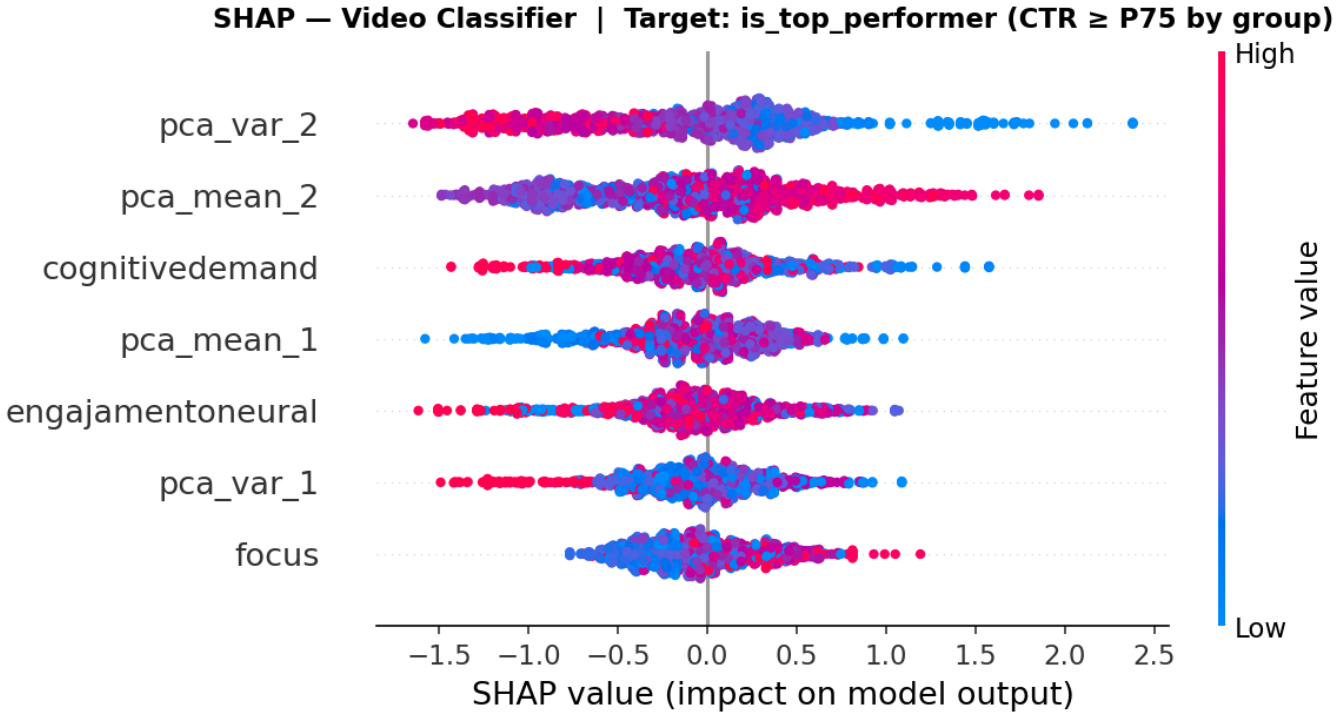

Figura 5.1 — Valores SHAP para o modelo de classificação de Top Performers (CTR) em vídeos.

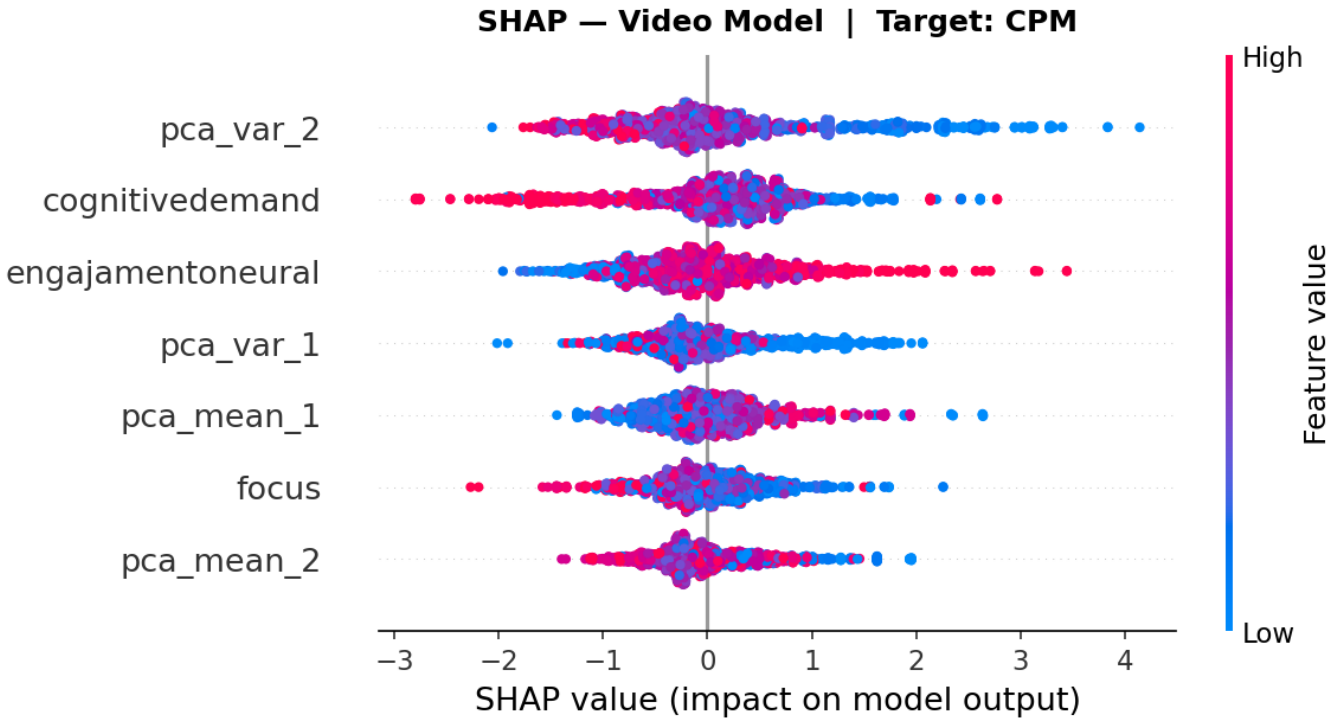

Figura 5.2 — Valores SHAP para o modelo de regressão de CPM em vídeos.

As Diretrizes Criativas

Vídeo: O Impacto Duplo de `pca_var_2`

A feature `pca_var_2` — que captura a **volatilidade temporal** dos padrões de ativação cognitiva ao longo do vídeo — emerge como o discriminador mais poderoso, exercendo um impacto duplo:

Perfil de `pca_var_2`	Significado Neurocientífico	Impacto no CTR	Impacto no CPM
Baixo (negativo)	Atenção sustentada e constante ao longo do vídeo; padrão cognitivo estável	**↑ Mais cliques** — o usuário mantém engagement contínuo até a ação	**↑ CPM mais alto** — a plataforma reconhece e precifica a qualidade
Alto (positivo)	Volatilidade caótica; picos e vales de atenção ao longo do vídeo	**↓ Menos cliques** — o engagement é interrompido antes da conversão	**↓ CPM mais baixo** — anúncios baratos, porém ineficazes

Implicação prática: Criativos de vídeo devem ser editados para manter uma narrativa cognitivamente coerente, evitando cortes abruptos ou estímulos visuais caóticos que fragmentem a atenção do espectador.

---

6. Clusterização Não-Supervisionada — Os Arquétipos

Metodologia

- **Algoritmo:** K-Means (K=2, n_init=20)
- **Features:** Componentes PCA (`pca_mean_1`, `pca_mean_2`, `pca_var_1`, `pca_var_2`) + métricas neurais brutas (`engajamentoneural`, `cognitivedemand`, `focus`)
- **Pré-processamento:** StandardScaler
- **Limpeza:** Hard-drop de `cognitivedemand > 1000` (1 registro removido)
- **Dataset:** 2.071 criativos de vídeo

Tabulação Cruzada: Cluster × Etapa do Funil

Cluster	Etapa do Funil	N	CTR Mediano	CPM Mediano (R$)	Engajamento Neural Médio	pca_var_2 Médio
0	Awareness	812	0,00473	10,85	72,71	−0,34329
0	Consideration	448	0,00627	7,64	72,73	−0,34012
0	Conversion	353	0,00770	12,11	74,00	−0,30478
0	**TOTAL**	**1.613**	**0,00542**	**10,36**	**73,07**	**−0,33186**
1	Awareness	240	0,00106	8,91	52,43	+1,16019
1	Consideration	126	0,00134	7,02	52,46	+1,14965
1	Conversion	92	0,00095	10,47	53,24	+1,13561
1	**TOTAL**	**458**	**0,00139**	**8,61**	**52,59**	**+1,15210**

Perfil dos Arquétipos

Dimensão	Cluster 0 — "Alta Performance"	Cluster 1 — "Baixa Performance"	Delta
CTR Mediano	0,00542	0,00139	**3,91× lift**
CPM Mediano	R$ 10,36	R$ 8,61	+R$ 1,75 (+18%)
Engajamento Neural	73,07	52,59	+20,48 (+39%)
pca_var_2	−0,33	+1,15	−1,48

Interpretação Executiva

O **Cluster 0** representa o arquétipo de vídeo de alta performance: alto engajamento neural sustentado (73,07) combinado com baixa volatilidade temporal (pca_var_2 = −0,33). Esses criativos mantêm a atenção do espectador de forma estável ao longo de toda a peça, resultando em uma taxa de cliques quase 4× superior.

O **Cluster 1** representa criativos com padrões cognitivos caóticos: menor engajamento (52,59) e alta volatilidade (pca_var_2 = +1,15). A atenção fragmentada se traduz diretamente em performance inferior.

O achado mais expressivo ocorre nas **campanhas de Conversão**, onde o Cluster 0 entrega CTR de 0,00770 contra 0,00095 do Cluster 1 — um multiplicador de **8,1×**.

Diretriz Executiva

> **Recomendação:** Todos os futuros criativos de vídeo devem ser pré-testados e otimizados para corresponder ao perfil neural do Cluster 0 (alto engajamento, baixa volatilidade temporal) **antes do lançamento em plataforma**.
>
> O investimento incremental de 18% em CPM é amplamente compensado pelo ganho de ~400% em cliques, resultando em um custo por clique (CPC) efetivo significativamente menor e um retorno sobre investimento publicitário (ROAS) superior.

Relatório gerado a partir do pipeline de EDA completo (Steps 1–8b). Dados: Havas.2/df_master.csv. Processamento: Python 3 · scikit-learn · SHAP.